Segmentación de inundaciones en Sentinel-1 con U-Net: supervisión débil, generalización geográfica y fusión con Sentinel-2

Flavio César Amayo Gamboa flavio.amayo.g@uni.pe
Gustavo Adolfo Huarcaya Delgado gustavo.huarcaya.d@uni.pe
Jhordy Joel Maximiliano Cusi jmaximilianoc@uni.pe
Sergio Mondragon Contreras sergio.mondragon.c@uni.pe
Facultad de Ingeniería Industrial y de Sistemas
Universidad Nacional de Ingeniería

31 de octubre de 2026

Abstract

Se implementa una U-Net desde cero en PyTorch para segmentar agua de inundación en imágenes SAR de Sentinel-1 sobre Sen1Floods11. Dentro de distribución el modelo alcanza IoU 0.681 y supera a la umbralización de Otsu por $+0.135$, con intervalo de confianza que no cruza cero. En la región geográfica retenida, Bolivia, el orden se invierte: Otsu gana por $+0.088$, también de forma significativa. Los resultados principales son cuatro. Primero, agregar los chips de etiqueta débil empeora la IoU de 0.681 a 0.587: llevan el entrenamiento a 4 412 chips, diecisiete veces más datos. Segundo, el análisis de fallos muestra que el 99.8 % de los falsos positivos y el 96.5 % de los negativos se concentran donde VV no separa agua de suelo: las densidades de retrodispersión de agua y suelo se solapan un 41.2 %, y los errores del modelo caen en esa zona. Tercero, fusionar Sentinel-2 sube la IoU a 0.850 ($+0.169$, significativo), pero la fusión no le gana al óptico solo; el radar solo vuelve a pesar bajo nube, donde con 16 chips nublados la diferencia no se puede afirmar. Cuarto, sobre la región peruana construida para este trabajo el modelo cae a IoU 0.003, pero la causa no es falta de generalización: la etiqueta oficial de Copernicus marca la extensión máxima de la inundación y no la superficie de agua visible en SAR, y su retrodispersión mediana (-9.2 dB) se parece al suelo de Sen1Floods11 (-8.4) y no a su agua (-16.5).

1 Motivación

Durante una inundación, saber *dónde* está el agua en las horas siguientes decide a dónde se manda la ayuda. El satélite óptico es la herramienta natural para mirar el terreno, pero las nubes que acompañan a la tormenta lo dejan ciego justo cuando más se lo necesita. El radar de apertura sintética de Sentinel-1 [10] atraviesa la nube y adquiere de noche, lo que lo convierte en la herramienta de facto para el mapeo rápido de inundaciones.

El problema tiene un precedente peruano concreto: durante las inundaciones de Lima de marzo de 2017 (El Niño costero) el Servicio de Gestión de Emergencias de Copernicus activó el mapeo rápido EMSN038 [2] para delinear la extensión del agua en Carapongo, Comas, Puente de Piedra y otros distritos de los ríos Rímac y Chillón.

El reto no es solo arquitectónico. No todas las etiquetas del conjunto son igual de confiables: Sen1Floods11 [1] distingue entre 446 *chips* anotados a mano por expertos y 4 385 generados automáticamente por umbralización, abundantes pero ruidosos. Decidir cómo combinar ambas fuentes es parte del trabajo, y este informe sostiene que esa decisión importa más que cualquier variante de la arquitectura.

2 Trabajos relacionados

Segmentación con codificador-decodificador. La U-Net [9] introdujo la combinación de un camino contractivo que gana contexto, uno expansivo que recupera resolución, y conexiones de

salto que devuelven al decodificador el detalle espacial que el codificador perdió al submuestrear. Esa combinación sigue siendo la referencia en segmentación con pocos datos anotados, que es el régimen de este problema: 252 chips de entrenamiento. Variantes posteriores agregan compuertas de atención sobre las conexiones de salto [7] o las anidan en varias escalas [12]; aquí se implementa la formulación original y se ablaciona la profundidad, por las razones de la Sección 5.2.

Detección de agua en SAR. El método clásico es umbralizar la retrodispersión: el agua, al ser una superficie lisa, refleja el pulso lejos del satélite y aparece oscura. La umbralización de Otsu [8] elige el corte que maximiza la varianza entre las dos clases, recalculándolo para cada escena. Esa recalibración por escena explica su ventaja fuera de distribución (Sección 5.3). Sen1Floods11 usa Otsu para generar sus etiquetas débiles.

Pérdidas para clases desbalanceadas. El agua ocupa el 9.5 % de los píxeles etiquetados del conjunto de entrenamiento. La entropía cruzada sola premia predecir "no agua" en todo; el coeficiente de Dice [6] optimiza directamente el solape entre predicción y verdad, y es insensible al tamaño del fondo. Acá se evalúan las dos y su combinación (Sección 5.2).

Índices ópticos de agua. Para el bono se usan dos índices normalizados clásicos: NDWI [5], que contrasta verde contra infrarrojo cercano, y MNDWI [11], que reemplaza el NIR por el SWIR y es más robusto en zona urbana. Ambos se calculan sobre las bandas de Sentinel-2 [3] que Sen1Floods11 distribuye emparejadas con el SAR.

3 Conjunto de datos

Sen1Floods11 cubre 11 eventos de inundación en distintos países y biomas. Cada chip es un GeoTIFF de 512×512 píxeles a 10 m de resolución, en EPSG:4326, con dos bandas SAR (VV y VH, en decibelios) y su contraparte óptica de Sentinel-2 de 13 bandas.

La etiqueta dorada tiene tres valores: 1 agua, 0 no agua y -1 sin dato. El -1 no es un detalle de formato: marca los píxeles que el anotador no pudo etiquetar, y tratarlo como "no agua" inventaría supervisión negativa donde no la hay. La pérdida de este trabajo lo enmascara explícitamente (Sección 4.2).

Partición. Se usa la oficial del conjunto: 252 chips de entrenamiento, 89 de validación y 90 de prueba, más los 15 de Bolivia, que los autores reservan como región geográfica independiente. Bolivia nunca se ve durante el entrenamiento, ni siquiera a través de los chips débiles: el conjunto débil incluye 224 chips bolivianos, y agregarlos "porque vienen del otro conjunto" sería una fuga de información hacia la región de prueba.

Normalización, medida y congelada. Las estadísticas se calculan solo sobre los 252 chips de entrenamiento: VV tiene media -10.39 dB con desvío 4.04, y VH media -17.24 con desvío 4.75. Los valores se recortan a los percentiles 0.1 y 99.9 antes de estandarizar, porque el mínimo observado (-65.45 dB en VV) es un artefacto aislado que aplastaría todo el rango útil. Calcular estas constantes sobre el conjunto completo filtraría información de prueba en la normalización.

4 Metodología

4.1 La U-Net, escrita desde cero

El enunciado exige implementarla sin copiar código de bibliotecas de segmentación existentes. La implementación tiene 31.04 M de parámetros y sigue la formulación original: cuatro bloques de bajada, un cuello, cuatro de subida y conexiones de salto por concatenación, no por suma, porque la

suma obligaría a que los dos tensores tengan la misma cantidad de canales y perdería la distinción entre el detalle del codificador y el contexto del decodificador.

Decisiones de diseño:

El relleno es "same", no "valid". La U-Net original recorta en cada convolución y su salida es más pequeña que la entrada. Aquí la salida mide 512×512, porque la máscara está georreferenciada: un recorte desplazaría la predicción respecto de las coordenadas del GeoTIFF y haría imposible compararla píxel a píxel con la etiqueta.

La entrada son dos canales, VV y VH, no tres. Replicar a tres para reusar pesos de ImageNet no tiene sentido aquí: no se parte de pesos preentrenados, y la retrodispersión en decibelios no es una imagen RGB.

La salida son logits, no probabilidades. La sigmoide se aplica dentro de la pérdida, que es numéricamente estable en su forma combinada.

4.2 La pérdida enmascarada

La pérdida ignora los píxeles con etiqueta -1 multiplicando por una máscara binaria antes de promediar. Hay un caso borde que importa: un lote donde ningún píxel tiene etiqueta utilizable. Devolver `torch.tensor(0.0)` ahí rompería el grafo de gradientes; se devuelve `(logits * 0).sum()`, que es cero *con* gradiente y deja el paso de optimización bien definido.

4.3 Cuatro decisiones del entrenamiento

La época se elige por IoU de validación, no por pérdida. La pérdida mezcla BCE y Dice y puede mejorar sin que la IoU se mueva; la métrica del enunciado es la IoU, así que es la que decide qué pesos se guardan.

La aumentación son volteos y giros de 90 grados, nada más. Un recorte aleatorio rompería la alineación con la grilla georreferenciada, y una rotación que no sea múltiplo de 90 grados interpolaría la máscara e inventaría píxeles de agua en los bordes.

Otsu se mide sobre los píxeles observados por ambos. El conjunto trae `S1OtsuLabelHand` para esta comparación; si Otsu se evaluara sobre todos los píxeles y la U-Net solo sobre los etiquetados, no sería una comparación entre pares.

Bolivia se evalúa una sola vez, al final. Usarla para elegir hiperparámetros la convertiría en una segunda validación y dejaría de medir generalización.

4.4 Protocolo de evaluación

Se reportan dos IoU porque miden cosas distintas y el enunciado pide la segunda. La *agregada* suma los conteos de todos los chips y divide una vez: pesa más los chips con mucha agua, y es la que se usa como principal porque pesa cada píxel por igual y no se desestabiliza en los chips casi secos. La *promedio por chip*, la que usan los autores del conjunto, da el mismo peso a cada chip y por eso es mucho más baja: hay chips casi secos donde la IoU es inestable. Un chip sin un solo píxel de agua ni predicho ni real tiene unión cero y se excluye del promedio, en vez de contarlo como 0 o como 1.

Con 90 chips de prueba y 15 de Bolivia, una diferencia de IoU puede ser ruido de muestreo, así que todas las comparaciones usan *bootstrap* [4] pareado sobre chips, nunca sobre píxeles: los píxeles vecinos de un chip están correlacionados (un río cubre miles de píxeles que son una sola observación) y remuestrearlos daría intervalos absurdamente angostos; las diferencias que no superan su intervalo se declaran no afirmables en vez de reportarse.

5 Experimentos y resultados

5.1 Evaluación en distribución (entregable 3)

La matriz de confusión, comentada. La matriz está balanceada, y eso descarta que el umbral esté mal puesto. En prueba hay 483 649 falsos positivos contra 489 788 falsos negativos, una diferencia

Cuadro 1: Desempeño de la mejor configuración sobre las tres particiones. La matriz de confusión es sobre píxeles observados, al umbral 0.5.

	Métricas					Confusión (px)			
Conjunto	IoU	IoU/chip	F_1	Precisión	Recall	VP	FP	FN	VN
Validación (89)	0.6521	0.4095	0.7894	0.8019	0.7773	1.74 M	0.43 M	0.50 M	17.6 M
Prueba (90)	**0.6808**	0.4178	0.8101	0.8111	0.8091	2.08 M	0.48 M	0.49 M	17.5 M
Bolivia (15)	0.6096	0.3758	0.7574	0.7849	0.7319	0.33 M	0.09 M	0.12 M	2.32 M

del 1.3 %, con precisión 0.811 y recall 0.809. Están balanceados, así que mover el umbral de 0.5 no mejoraría la IoU: solo cambiaría un tipo de error por el otro. Eso obliga a buscar la causa del error en otra parte, que es lo que hace la Sección 5.6.

La exactitud sería engañosa y por eso no se reporta como resultado. Los verdaderos negativos son 17.5 M contra 2.08 M de verdaderos positivos: predecir "no agua" en todos los píxeles daría 88 % de exactitud sin segmentar nada. Por eso la métrica del conjunto es la IoU de la clase agua, que ignora los verdaderos negativos por construcción.

La brecha entre las dos IoU mide el desbalance entre chips. La agregada es 0.6808 y la promedio por chip 0.4178, una diferencia de 0.26. Como la agregada pesa cada píxel igual y la promedio pesa cada chip igual, esa brecha dice que el modelo funciona bien en los chips con mucha agua y mal en los casi secos. Los autores del conjunto reportan la segunda, y por eso se reportan las dos.

De prueba a Bolivia el modelo cae en recall, no en precisión: la precisión baja de 0.811 a 0.785 (un 3 %) mientras el recall cae de 0.809 a 0.732 (un 10 %). El modelo no inventa más agua en terreno nuevo, deja de encontrarla. Es consistente con la hipótesis de la recalibración por escena de la Sección 5.3: un umbral aprendido en otras regiones queda demasiado exigente cuando el histograma se corre.

5.2 Estudio de ablación (entregable 2)

Cuadro 2: Las siete corridas de la ablación. Todas comparten semilla, partición y presupuesto de cómputo (~10 minutos); las corridas con chips débiles usan menos épocas porque cada época recorre más datos.

Corrida	Factor	Chips	Épocas	IoU prueba	IoU Bolivia
a_solo_dorados	supervisión	252	60	**0.6808**	0.6096
a_debiles_1000	supervisión	1 252	12	0.5987	0.6678
a_debiles_todos	supervisión	4 412	4	0.5871	0.6672
b_bce	pérdida	252	60	0.6692	0.6343
b_dice	pérdida	252	60	0.6749	0.6043
c_somera	profundidad	252	60	0.6540	**0.6761**
c_profunda	profundidad	252	60	0.6711	0.6526

Etiquetas débiles. Pasar de 252 a 4 412 chips, diecisiete veces más datos, baja la IoU de prueba de 0.681 a 0.587. La explicación está en cómo se generaron esas etiquetas: por umbralización automática, es decir por el mismo método clásico contra el que se compara el modelo. Entrenar con ellas no le enseña a la red a segmentar agua; le enseña a imitar a Otsu, errores incluidos.

En Bolivia, en cambio, los chips débiles *mejoran* la IoU de 0.610 a 0.668, porque empujan al modelo hacia el umbral de Otsu, que allí alcanza 0.697. Entre las siete corridas la correlación de rangos entre la IoU de prueba y la de Bolivia es $\rho = -0.786$: lo que ayuda dentro de distribución perjudica fuera. Para una región nueva conviene incluir los débiles; para los eventos ya vistos, solo los dorados.

El presupuesto está igualado en pasos, no en épocas, y eso es lo que hace limpia la comparación: las tres corridas ven aproximadamente la misma cantidad de chips (15 120, 15 024 y 17 648 respectivamente) porque las épocas se bajan a medida que el conjunto crece. Una época sobre 4 412 chips serían diecisiete veces más actualizaciones que una sobre 252, y la tabla mediría *cuánto entrenó* en vez de *con qué datos*.

La función de pérdida tiene poco efecto. BCE sola da 0.6692, Dice sola 0.6749, y la combinación con peso 0.5, la configuración publicada, 0.6808. La diferencia entre los tres extremos es de 0.012, del orden del ruido con 90 chips.

La profundidad tampoco, y en Bolivia se invierte. La variante somera queda última en prueba (0.6540) y primera en Bolivia (0.6761). Es un indicio consistente con el resto del informe: la capacidad extra que ayuda dentro de distribución se gasta en memorizar características de las regiones vistas.

5.3 Generalización geográfica (entregable 4)

Cuadro 3: U-Net contra umbralización de Otsu, con bootstrap pareado sobre chips y 10 000 remuestreos.

Conjunto	IoU U-Net	IoU Otsu (S1OtsuLabelHand)	Δ	IC95 % de Δ	¿Significativa?
Prueba (90 chips)	**0.6808**	0.5458	$+0.1350$	$[+0.0705, +0.2091]$	**sí**
Bolivia (15 chips)	0.6096	**0.6973**	-0.0877	$[-0.1655, -0.0220]$	**sí**

El orden se invierte, y las dos diferencias son significativas. Dentro de distribución la U-Net le gana a Otsu por $+0.135$; en la región retenida *pierde* por -0.088, con un intervalo que tampoco cruza cero. En la región no vista, la U-Net queda por debajo de Otsu.

La caída de la U-Net al pasar de prueba a Bolivia es $+0.0713$, con intervalo $[-0.0888, +0.3085]$ que sí cruza cero. Esa comparación no es pareada (son chips distintos, sin correspondencia uno a uno) y con 15 chips bolivianos no alcanza para afirmarla. Se reporta igual, con su intervalo, en vez de mostrar solo la comparación que sí resulta significativa.

Dos hipótesis sobre la causa. La primera es la recalibración por escena: Otsu elige su umbral en cada imagen, de modo que un corrimiento global del histograma (distinto ángulo de incidencia, distinta humedad del suelo, distinta rugosidad) no lo afecta, mientras que la U-Net lleva su decisión aprendida de otras regiones. La segunda es la cobertura del suelo: los eventos de entrenamiento no incluyen el tipo de vegetación y relieve bolivianos, y la Sección 5.6 muestra que la mayor parte del error cae donde las dos clases comparten retrodispersión.

5.4 La región de prueba peruana

La región peruana se construye en dos partes: la grilla de chips con su máscara de referencia (EMSN038) y la escena Sentinel-1 del 17 de marzo de 2017 (HyP3).

La etiqueta sale del geodatabase de EMSN038, capa `Potential_Maximum_flood`: 13 polígonos, 13.58 km^2. Esta capa delimita la extensión máxima que alcanzó la inundación según las imágenes ópticas del 18 y 21 de marzo; `DamAssess_A` evalúa daños sobre esos mismos polígonos.

Se usan los 13 polígonos, no solo los 2 que quedan fuera del cauce. Los otros 11 son el río a altura máxima, verificado: coinciden con la capa `Riverbank`. Sen1Floods11 etiqueta *agua*, no "inundación", y dejar el cauce afuera crearía un desacuerdo de criterio con el entrenamiento que después se confundiría con un fallo de generalización. La Sección 5.5 muestra que el cauce no se ve como agua en SAR.

Fuera de la huella de las imágenes post-evento, la etiqueta es -1. Solo dos de las seis huellas del producto son posteriores al evento, las WorldView-2 del 18 y del 21 de marzo; donde nadie miró, escribir 0 inventaría supervisión negativa. La grilla se ancla a múltiplos exactos del paso de píxel de Sen1Floods11 (10 m en EPSG:4326) desde $(0, 0)$, para que recortes distintos produzcan chips en las mismas coordenadas.

La región queda en 58 chips de 512×512, 18 con algún píxel de agua y 40 enteramente secos, con el 89.7 % de los píxeles observados. Entre ellos el agua es el 1.01 %, contra 9.51 % en el entrenamiento: Lima es casi diez veces más seca que lo que el modelo vio. Ese desbalance es una hipótesis medida, no supuesta, sobre la brecha, aunque la Sección 5.5 mostrará que no es la que manda.

La escena Sentinel-1 se obtuvo de HyP3 (ASF/NASA), no de Google Earth Engine. El servicio produce bajo demanda los mismos tres parámetros con los que se construyó Sen1Floods11 (`sigma0`, decibelios, 10 m), de modo que el producto es comparable sin montar una cadena de preprocesamiento propia, que habría metido un confundidor en el entregable que mide generalización. Queda una diferencia: HyP3 aplica corrección radiométrica de terreno (aplana el relieve con un DEM) y el `COPERNICUS/S1_GRD` de GEE con que se armó Sen1Floods11 no; en terreno plano es despreciable, pero en el valle del Rímac algo pesa. Granule `S1B_IW_GRDH_1SDV_20170317T103823`, path 171 descendente, un día antes de la delineación óptica. Cada chip se reproyecta a la grilla que *ya* tiene su etiqueta (se lee su `transform` y su CRS y se reproyecta a eso), así que la correspondencia píxel a píxel no depende de que dos cálculos independientes coincidan. Diez de los 58 chips caen fuera de la franja y se descartan antes de medir: evaluarlos sumaría aciertos triviales sobre píxeles que nadie observó.

IoU 0.0028 contra 0.6808 en prueba, una brecha de -0.678 con IC95 % $[-0.761, -0.570]$ (no pareado: son chips distintos). Un desplome de ese tamaño admite dos lecturas incompatibles (o el modelo no generaliza, o la etiqueta no marca lo que el modelo predice). La sección siguiente evalúa ambas.

5.5 Por qué el desplome de Lima no mide generalización

Primero: la alineación es correcta, así que el 0.0028 no es un error de georreferenciación: la Figura 1 lo muestra.

Segundo: Otsu también fracasa, y Otsu no aprende nada. Con la misma función sobre las dos regiones, el umbral por chip sobre VV da IoU 0.0108 en Lima contra 0.3530 en Bolivia: cae 33 veces. Como Otsu recalibra dentro de cada imagen y no arrastra nada aprendido, su fallo no puede deberse a falta de generalización.[1]

Tercero: la etiqueta está anticorrelacionada con la señal. Dentro de lo etiquetado agua, el 8.7 % de los píxeles está bajo -15 dB; fuera, el 16.3 %. Los píxeles oscuros son casi el doble de frecuentes *fuera* del agua declarada que dentro. Ningún umbral ni modelo puede recuperar una etiqueta que apunta al revés que la evidencia.

Cuadro 4: Firma de radar de cada capa candidata del geodatabase, contra el agua y el suelo que el modelo sí aprendió. Ninguna capa de Lima se parece al agua; `Potential_Maximum_flood` se parece al *suelo*.

Capa	Mediana VV	% bajo -15 dB	Píxeles
`Riverbank` (el cauce)	-6.97 dB	1.4 %	74 079
`Potential_Maximum_flood` (la usada)	-9.16 dB	8.7 %	136 104
`WatrcrsA`	-11.70 dB	19.4 %	40 172
`LakeresA`	-15.11 dB	51.0 %	1 788
Sen1Floods11, **suelo**	-8.36 dB	2.5 %	2 372 533
Sen1Floods11, **agua**	$\mathbf{-16.47}$ **dB**	**65.4 %**	451 901

Firma de radar del cauce. El Cuadro 4 muestra que el *cauce* es la capa más brillante de todas, -6.97 dB, con apenas 1.4 % de píxeles oscuros. El Rímac de marzo de 2017 era un torrente de montaña turbulento y cargado de sedimento en un cañón urbano, y una superficie rugosa retrodispersa como suelo; lo que el radar ve negro es el agua *lisa*. La confirmación está en la última fila de Lima: `LakeresA`, lagunas de agua quieta, es la única que se acerca al agua dorada. En el vocabulario de la Sección 5.6, Lima es el modo 3, agua brillante que se ve como suelo, extendido a un evento entero: ahí pesaba el 2.5 % de los falsos negativos sobre 23.3 M de píxeles de Asia y África, aquí domina la escena completa.

Tampoco la rescata la detección de cambio. Queda una salida: la detección de cambio, que es como Copernicus EMS mapea inundaciones con SAR. Se bajó la escena del 5 de marzo (mismo

[1] Ese 0.3530 es un Otsu ingenuo sobre VV, no el `S1OtsuLabelHand` del Cuadro 3 (0.6973 en Bolivia, con preprocesamiento propio). Se usa el ingenuo porque es el único que existe para Lima, y se aplica igual en ambas regiones.

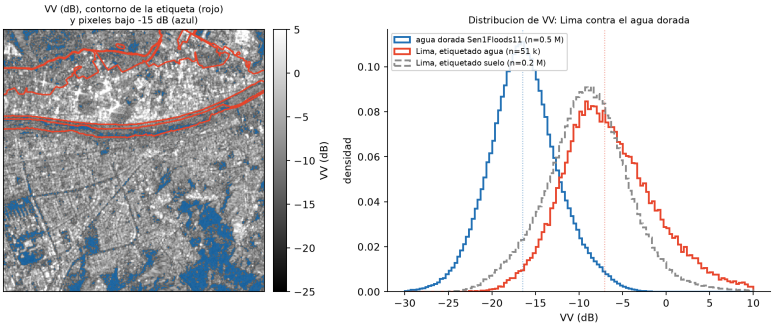


Figura 1: *Izquierda*: el contorno de la etiqueta (rojo) sigue el cauce (la alineación es correcta), pero los píxeles oscuros (azul) están repartidos por toda la escena y no dentro del contorno. *Derecha*: las dos poblaciones de Lima se superponen entre sí y ninguna cae donde cae el agua dorada. Lo etiquetado agua es, si acaso, más brillante que lo etiquetado suelo.

path, misma hora, doce días antes: mismo ángulo de incidencia píxel a píxel) y se midió. Centrando la diferencia por escena, dentro de lo etiquetado agua VV sube $+0.78$ dB mientras fuera no se mueve (-0.01). Barriendo todos los umbrales de caída y quedándose con el mejor (elegido viendo la respuesta, así que es una *cota superior* de cualquier detector por umbral global) el IoU máximo es 0.0242. El límite no es el modelo de una fecha: el área señalada no se oscureció, se aclaró.

Qué queda en pie. No queda en pie leer el 0.0028 como medida de generalización: la etiqueta marca la extensión máxima de la inundación, no la superficie de agua visible en SAR que el modelo predice, así que comparar ambas mide el desacuerdo entre dos definiciones. Bolivia sigue siendo el experimento de generalización válido. Sobre la brecha de Lima pesan varias hipótesis: la definición de la etiqueta (H1) y la firma turbulenta del cauce (H2), puestas a prueba con el Cuadro 4 y la detección de cambio; el desbalance de clases, 1.01 % frente a 9.51 % (H5), medido; y tres no medidas: el desfase temporal, el entorno urbano y el distinto procesamiento radiométrico (H3, H4, H6). Sí queda en pie, y es un límite que conviene documentar, que un producto de mapeo rápido de Copernicus no sirve como verdad de terreno para SAR aunque describa la misma inundación, la misma semana y el mismo lugar: ¿hasta dónde pudo llegar el agua? no es la pregunta que responde una etiqueta de Sen1Floods11, ¿qué píxel es agua? La diferencia de medianas es de 7.3 dB.

5.6 Fallos característicos del SAR (entregable 5)

Para separar los errores del sensor de los del modelo se construyen los histogramas de VV condicionados a la verdad, uno para agua y uno para suelo, sobre los 23.3 M de píxeles observados de prueba y Bolivia, y se mide cuánto se solapan.

Cuadro 5: Los cuatro modos de fallo, con su peso medido. La zona ambigua va de -17.75 a -4.75 dB.

Modo	% de los FP	% de los FN	Zona de VV
1 — solape irreducible	75.5 %	94.0 %	ambigua
2 — seco y liso se ve como agua (especular)	24.3 %	—	ambigua
3 — agua brillante se ve como suelo (viento, doble rebote)	—	2.5 %	ambigua
4 — el error cae donde su propia clase domina	0.2 %	3.5 %	**clara**
En zona ambigua de VV	**99.8 %**	**96.5 %**	

Las medianas lo dicen directo: los falsos positivos tienen VV -14.6 dB, mucho más oscura que el suelo típico (-9.4), y los falsos negativos -10.6, mucho más brillante que el agua típica (-17.4).

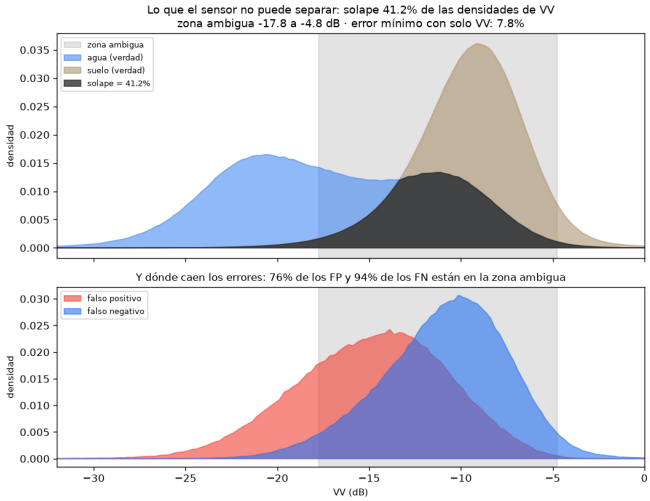


Figura 2: *Arriba*: densidades de VV condicionadas a la verdad. El área negra es el solape, 41.2 % de la masa. La banda gris es la zona donde ninguna clase domina el bin. *Abajo*: dónde caen los errores del modelo. El 75.5 % de los falsos positivos y el 94 % de los negativos están dentro de esa zona.

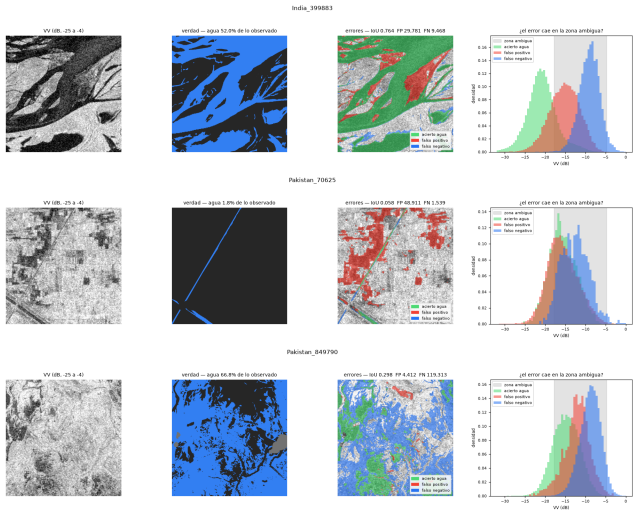


Figura 3: Un ejemplo de cada modo de fallo del sensor; en cada fila: VV en dB, la verdad, los errores (acierto de agua verde, falsos positivos rojo, falsos negativos azul) y el histograma de VV con la zona ambigua sombreada. *Modo 1*, solape (`India_399883`): el error cae en la zona gris. *Modo 2*, especular (`Pakistan_70625`): campos secos marcados como agua. *Modo 3*, agua brillante como suelo (`Pakistan_849790`): el agua turbulenta se pierde como falso negativo.

La comprobación de la cota. El error de Bayes mirando solo VV (con las proporciones reales, donde el agua es el 12.8 % de los píxeles) es 7.81 %, y el modelo comete 4.83 %. Está por debajo de la cota, que es lo que tiene que pasar: recibe VV *y* VH y además ve el contexto espacial.

La sombra de radar, un fallo que este conjunto no muestra. El enunciado nombra la sombra de radar entre los fallos característicos del SAR. Es un artefacto geométrico: donde el relieve bloquea el pulso, la ladera opuesta queda sin retorno y aparece negra, indistinguible del agua lisa. No figura entre los cuatro modos cuantificados porque Sen1Floods11 cubre sobre todo llanuras y deltas, donde la geometría apenas la produce, y porque las etiquetas doradas se trazaron sobre escenas ya corregidas por terreno. Donde sí pesaría es en relieve pronunciado como el cañón del Rímac, el mismo terreno de la región peruana (Sección 5.4): una sombra sobre la ladera se leería como agua y un escorzo brillante escondería el cauce.

Sensibilidad a los umbrales. Barriendo 15 combinaciones de las dos constantes que definen la zona ambigua, la fracción de error en esa zona va del 85.6 % al 100 % en los falsos positivos y del 88.8 % al 99.1 % en los negativos: el reparto se mueve, la conclusión no.

5.7 Fusión con Sentinel-2 (entregable 6, bono)

Si el radar no separa las clases, una banda óptica puede hacerlo. Se entrena la misma U-Net tres veces (solo SAR, solo óptico, y los dos fusionados) sobre los mismos chips, la misma partición y la misma semilla; lo único que cambia son los canales de entrada. El modelo óptico usa las bandas B3, B4, B8 y B11 más los índices NDWI y MNDWI. Los 446 chips dorados tienen las tres piezas, así que no se pierde ninguno.

Cuadro 6: Separación de cada capa óptica, con el mismo coeficiente de solape que la Sección 5.6 aplica a VV, sobre los 90 chips de prueba.

Capa	Agua	Suelo	Solape	Capa	Agua	Suelo	Solape
Rojo B4	0.107	0.083	80.0 %	SWIR B11	0.038	0.198	13.9 %
Verde B3	0.128	0.107	70.9 %	NDWI	0.165	-0.395	11.3 %
NIR B8	0.092	0.273	15.2 %	**MNDWI**	**0.495**	$\mathbf{-0.285}$	**9.4 %**
VV en dB, de referencia: agua -17.4, suelo -9.4, solape **41.2 %**							

MNDWI deja un 9.4 % de solape donde VV deja 41.2 %: lo reduce 4.4 veces. Dos observaciones que la tabla deja ver: el verde y el rojo por sí solos separan *peor* que VV (70.9 % y 80.0 %), y el salto está en el infrarrojo, donde la física lo pone.

Cuadro 7: Bootstrap pareado sobre chips, 10 000 remuestreos. Los 90 chips de prueba se parten en 74 despejados y 16 nublados (más del 10 % de píxeles con reflectancia en azul B2 > 0.25).

Comparación	Grupo	Δ IoU	IC95 %	¿Significativa?
fusión vs. SAR	todos	$+0.1690$	$[+0.0910, +0.2538]$	**sí**
	despejados	$+0.1768$	$[+0.0913, +0.2690]$	**sí**
	nublados	$+0.1220$	$[+0.0186, +0.3405]$	**sí**
óptico vs. SAR	todos	$+0.1704$	$[+0.0876, +0.2614]$	sí
	despejados	$+0.1832$	$[+0.0937, +0.2808]$	sí
	nublados	$+0.0938$	$[\mathbf{-0.0327}, \mathbf{+0.3346}]$	**no**
fusión vs. óptico	todos	-0.0013	$[-0.0122, +0.0093]$	no
	despejados	-0.0063	$[-0.0168, +0.0007]$	no
	nublados	$+0.0282$	$[-0.0020, +0.0567]$	no

Las IoU de prueba son 0.6808 (SAR), 0.8511 (óptico) y 0.8498 (fusión); la corrida de SAR reproduce el 0.6808 del resto del informe.

El bono funciona, pero la fusión no le gana al óptico solo. La mejora sobre el SAR es $+0.169$, pero la diferencia entre fusión y óptico es -0.0013 con el intervalo cruzando cero: con cielo despejado el radar no aporta nada que el óptico no tenga.

Con nubes, solo la ganancia de la fusión sigue siendo significativa. Fusión contra óptico pasa de -0.0063 a $+0.0282$, con el intervalo rozando el cero por dos milésimas: es donde la física dice que el radar tiene que aportar, pero con 16 chips nublados no se puede afirmar.

6 Discusión crítica de las limitaciones

Pocos chips nublados. Medido sobre los 90 de prueba: nubosidad mediana 0.2 %, 2 chips por encima del 25 % y ninguno por encima del 50 %. El conjunto dorado se eligió donde el óptico era etiquetable a mano, así que está sesgado hacia cielo despejado. El régimen que motiva usar radar, óptico ciego y SAR solo, no tiene aquí un solo chip.

Una sola región retenida. La inversión U-Net/Otsu en Bolivia es significativa, pero descansa en 15 chips de una sola región. No se puede distinguir si el modelo falla por la región *boliviana* o por *cualquier* región no vista, y el conjunto no ofrece más regiones retenidas particionadas.

Techo de los chips débiles. El presupuesto está igualado en pasos, así que la comparación de *qué datos* es limpia; no se midió qué pasaría con 4 412 chips y las 60 épocas completas, diecisiete veces más cómputo. Una corrida así no superaría a la dorada, cuyo techo es Otsu, pero eso es conjetura. Además, solo se probó concatenar las dos fuentes; no se probó preentrenar con débiles y ajustar con dorados, ni ponderar su pérdida. Las corridas de ablación usan una sola semilla y sin intervalo, así que las diferencias menores a $\sim$0.02 no se interpretan.

Lima sin cifra de generalización. Queda sin responder cuánto cae el modelo en Lima: haría falta una delineación de agua trazada sobre la propia escena SAR del 17 de marzo, que EMSN038 no provee. La única región retenida con cifra válida sigue siendo Bolivia.

Variantes de arquitectura. Se ablacionó profundidad y pérdida, pero no se probaron las variantes que el enunciado menciona (Attention U-Net [7], U-Net++ [12]). Dado que la Sección 5.6 ubica el 99.8 % de los falsos positivos en la zona ambigua de VV, el retorno esperado de esa búsqueda es bajo, aunque es una predicción, no un resultado medido. La cota de Bayes de esa sección, además, se calculó solo sobre VV, no sobre VV y VH conjuntos.

7 Conclusiones

Primero, más datos empeoran cuando la etiqueta la produjo el método que se quiere superar: multiplicar el conjunto por diecisiete con chips de umbralización baja la IoU de 0.681 a 0.587. No enseña a segmentar agua, enseña a imitar a Otsu.

Segundo, el método clásico gana fuera de distribución, por -0.088 en Bolivia y de forma significativa. La ventaja de Otsu es la que parecía su limitación: recalcula su umbral en cada escena.

Tercero, casi todo el error cae donde VV es ambiguo, y eso condiciona cómo leer lo demás: el 99.8 % de los falsos positivos cae donde las densidades de agua y suelo se solapan, y el modelo opera por debajo de la cota de Bayes de una sola banda. La fusión con Sentinel-2 sube la IoU a 0.850 porque MNDWI reduce ese solape 4.4 veces, pero no le gana al óptico solo, y el régimen donde el radar vuelve a ser necesario, el nublado, casi no está en el conjunto.

Cuarto, la etiqueta oficial de una inundación real no sirve como verdad de terreno para SAR. En la región peruana el modelo cae a IoU 0.003, pero Otsu cae con él, los píxeles oscuros abundan más fuera del agua declarada que dentro, y entre el antes y el durante la zona señalada se *aclara*. La delineación de Copernicus marca la extensión máxima de la inundación, no la superficie de agua visible en SAR.

La vía de mejora no es arquitectónica: hacen falta chips con nubosidad realista, para saber si la fusión sobrevive al caso que motiva usar radar, y delineaciones de agua trazadas sobre la propia escena SAR para medir generalización.

Reproducibilidad

Todo se reproduce con `python pregunta2/ejecutar_todo.py`, que encadena las 20 etapas desde la descarga hasta este documento y salta las que ya tienen artefacto. El repositorio incluye pruebas unitarias en `tests/`, que el orquestador ejecuta, para el bootstrap pareado y el cálculo del solape.

Referencias

[1] Derrick Bonafilia, Beth Tellman, Tyler Anderson, and Erica Issenberg. Sen1floods11: A georeferenced dataset to train and test deep learning flood algorithms for sentinel-1. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, pages 210–211, 2020.

[2] Copernicus Emergency Management Service. Copernicus ems activation emsn038: Flood in lima, peru. `https://mapping.emergency.copernicus.eu/activations/EMSN038/`, 2017.

[3] Matthias Drusch, Umberto Del Bello, Sébastien Carlier, Olivier Colin, Veronica Fernandez, Ferran Gascon, et al. Sentinel-2: Esa's optical high-resolution mission for gmes operational services. *Remote Sensing of Environment*, 120:25–36, 2012.

[4] Bradley Efron and Robert J. Tibshirani. *An Introduction to the Bootstrap*. Chapman and Hall/CRC, 1994.

[5] Stuart K. McFeeters. The use of the normalized difference water index (ndwi) in the delineation of open water features. *International Journal of Remote Sensing*, 17(7):1425–1432, 1996.

[6] Fausto Milletari, Nassir Navab, and Seyed-Ahmad Ahmadi. V-net: Fully convolutional neural networks for volumetric medical image segmentation. In *Fourth International Conference on 3D Vision (3DV)*, pages 565–571, 2016.

[7] Ozan Oktay, Jo Schlemper, Loic Le Folgoc, Matthew Lee, Mattias Heinrich, Kazunari Misawa, et al. Attention u-net: Learning where to look for the pancreas. In *Medical Imaging with Deep Learning (MIDL)*, 2018.

[8] Nobuyuki Otsu. A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man, and Cybernetics*, 9(1):62–66, 1979.

[9] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 234–241, 2015.

[10] Ramón Torres, Paul Snoeij, Dirk Geudtner, David Bibby, Malcolm Davidson, Evert Attema, Pierre Potin, et al. Gmes sentinel-1 mission. *Remote Sensing of Environment*, 120:9–24, 2012.

[11] Hanqiu Xu. Modification of normalised difference water index (ndwi) to enhance open water features in remotely sensed imagery. *International Journal of Remote Sensing*, 27(14):3025–3033, 2006.

[12] Zongwei Zhou, Md Mahfuzur Rahman Siddiquee, Nima Tajbakhsh, and Jianming Liang. Unet++: A nested u-net architecture for medical image segmentation. In *Deep Learning in Medical Image Analysis (DLMIA)*, pages 3–11, 2018.